


Presentasi Data Engineering


Group 16:
Marcellino Wilson Rusli - 2802417560

Jason Alexander Wljaya - 2802402395

Timothy Jason Latief - 2802403435



9 Juni 2026



Role data engineering in the data ecosystem



Pipeline Builder

Merancang & membangun pipeline data yang handal, scalable, dan otomatis dari sumber ke tujuan.



Enabler Analytics

Menyiapkan data siap konsumsi untuk tim BI, Data Scientist, dan stakeholder.



Data Steward

Menjamin kualitas, integritas, dan konsistensi data yang mengalir melalui sistem.



Data Security

Memastikan kelancaran aliran data (pipelining) serta mengelola akses dan keamanan data sensitif.



Tool Selector


Memilih tools yang tepat (Airflow, dbt, Spark, BigQuery) sesuai kebutuhan bisnis.



Optimization Performance

Meningkatkan kecepatan dan efisiensi sistem penyimpanan dan pemrosesan data, seringkali menggunakan *framework* seperti Apache Spark

Data Architecture dan pipeline components




Apa itu Data Engineering Architecture?

Data Engineering Architecture adalah rancangan atau struktur bagaimana data dikumpulkan, disimpan, diproses, dan digunakan dalam suatu sistem perusahaan atau aplikasi.



- Raw Source: sumber data(dimana data didapatkan)
- Data Ingestion: Pengambilan data, pengumpulan data, dan pemindahan data dari source ke sistem pemrosesan. Contohnya:
 1. Batch Ingestion
 2. Real time Ingestion
- Data Storage: Data disimpan di dalam sistem untuk diproses selanjutnya, contohnya:
 1. Data Warehouse: Penyimpanan terstruktur untuk analitik (untuk data bersih dan terstruktur)
 2. Data LakeHouse: Penyimpanan yang menyimpan data dalam format asli (terstruktur, semistruktur, dan tak terstruktur)
 3. Modern Data Stack: Gabungan advantages dari keduanya.
- Data Transformation: Data mentah diubah menjadi data yang siap dianalisis
- Consumption Data: Data yang sudah diproses dan sudah siap digunakan oleh pengguna.

Data Architecture dan pipeline components



Apa itu Data Engineering pipeline components?


Data Engineering Pipeline Components adalah komponen atau bagian-bagian utama yang membentuk sebuah data pipeline.

Pipeline sendiri adalah alur proses data dari sumber sampai siap digunakan.


Data Pipeline components itu merupakan bagian dari data architecture.

Komponen Utama Data Engineering pipeline components:

- 1.Data Source = Tempat asal data,contohnya: Database,File csv/excel,sensor IOT
- 2.Data Ingestion = Proses pengambilan dan pengumpulan data dari data source
- 3.Data Storage = Tempat penyimpanan data,Contohnya:Datalake,Data warehouse
- 4.Data Transformation = Tahapan dimana data diolah agar siap untuk digunakan
- 5.Data Orchestration = Mengatur workflow pipeline otomatis
- 6.Data Quality & Monitoring = Memastikan data dan pipeline berjalan dengan lancar
- 7.Data Consumption = Data siap digunakan oleh pengguna dan konsumen



* Perbedaan ETL dan ELT



ETL — Extract → Transform → Load

Transformasi SEBELUM masuk storage

Cocok data terstruktur, volume kecil-menengah

Tools: Talend, SSIS, Informatica, Python scripts

Butuh dedicated transform server

Privasi lebih terjaga (data sensitif ditransform dulu)

Lebih lambat dan fleksibilitas rendah

VS

ELT — Extract → Load → Transform

Transformasi SETELAH data masuk storage

Cocok data besar, cloud-native environments


Tools: dbt, BigQuery, Snowflake, Databricks

Manfaatkan kekuatan compute cloud warehouse

Fleksibel – analisis bisa re-transform kapan saja


Sangat cepat dan fleksibilitas tinggi

Perbedaan ETL dan ELT






Pemilihan Tools untuk Kebutuhan Bisnis atau Analisis



Pemilihan tools dalam data engineering merupakan proses dimana kita menentukan software yang paling sesuai dengan data set yang ada untuk memenuhi tujuan analisis pada dataset tersebut. Tiap tools memiliki fungsi dan keunggulannya masing - masing sehingga penggunaannya harus disesuaikan dengan jenis, jumlah, dan hasil data yang ingin dicapai


sebagai contoh, pada proyek kami pentaho digunakan untuk proses ETL dan integrasi data dan MySQL digunakan untuk menyimpan dan power BI digunakan untuk visualisasi dan pembuatan dashboard. Dengan memilih tools yang tepat kami dapat mengolah data lebih cepat dan efisien dan mengambil keputusan yang lebih baik




Memastikan Kualitas dan Reliabilitas Data dalam Desain Pipeline

kualitas dan reabilitas pada data merupakan aspek yang penting untuk memastikan bahwa data yang digunakan saat analisis atau modeling adalah data yang akurat, konsisten dan dapat dipercaya. Dalam data pipeline, kualitas data penting untuk mendukung hasil analisis yang sempurna.

Untuk menjaga kualitas data tetap bersih, pada proyek kami, kami melakukan data cleansing pada pentaho lalu melakukan standarisasi format data. selain itu reabilitas data dijaga dengan memastikan proses pipelint tetap berjalan stabil dan menghasilkan data yang konsitsten tanpa menyebabkan kehilangan atau kerusakan data. Dengan cara ini kami dapat mengoptimalkan analisis data pada proyek kali ini



pipeline architecture & layers



* Load Raw Data



CSV file input




Table output

Step name **CSV file input**

Filename

CSV file input->membaca data mentah dari file CSV

Step name **Table output**

Connection **hasil_connection**

Target schema

Target table **hospital**

Commit size **1000**

Truncate table ☒

Ignore insert errors ☐

Specify database fields ☐

Table output → menyimpan hasil dari csv ke dalam database


Cuplikan Data:

id	nama	propinsi	kab	alamat	jenis
1110053	RS Arun Lhokseumawe	Aceh	Kota Lhokseumawe	Jl. Plaju Komplek Perumahan PT Arun Batuphat Timur...	Rumah Sakit Umum
1106014	RS Umum Fandika	Aceh	Aceh Tengah	Jl. Terminal Simpang Warji Blangkolak 1 Kec. Bebe...	Rumah Sakit Umum
1171110	RS Umum Daerah Meuraxa	Aceh	Kota Banda Aceh	Jl. Soekarno Hatta Km. 2 Desa Mibo Kecamatan Banda...	Rumah Sakit Umum
1171163	RS Gigi Mulut Universitas Syiah Kuala	Aceh	Kota Banda Aceh	Jl. Prof A. Madjid Ibrahim I No. 5 Banda Aceh Kel...	Rumah Sakit Khusus Gigi dan Mulut
1102027	RS Umum Daerah Kota Subulussalam	Aceh	Kota Subulussalam	Jl. Hamzah Fansyuri (Subulussalam-Rundeng) Kec. ...	Rumah Sakit Umum
1106013	RS Umum Daerah Datu Beru Takengon	Aceh	Aceh Tengah	Jl. Rumah Sakit No.153 Kec. Kebayakan	Rumah Sakit Umum
1109028	RS Umum Mufid	Aceh	Pidie	JL. PROF. A. MAJID IBRAHIM, NO. 62-66, KEC. KOTA S...	Rumah Sakit Umum
1174022	RS Umum Metro Medical Center	Aceh	Kota Lhokseumawe	Jl. Merdeka Barat No. 70 A, Kecamatan Muara Dua, K...	Rumah Sakit Umum
1117025	RS Umum Daerah Muang Kute Redelong Bener Meriah	Aceh	Bener Meriah	Jl. Simpang Teritit-Pondok Baru, Simpang Empat Kut...	Rumah Sakit Umum
1106025	RS Gayo Medical Centre	Aceh	Aceh Tengah	Jl. Paya Tumpi-Mandale, No. 126 Kec. Kebayakan	Rumah Sakit Umum
1104013	RS Ibu dan Anak Keluarga Desa	Aceh	Aceh Tenggara	Jl. Iskandar Muda No. 58 Kutacane	Rumah Sakit Khusus Ibu dan Anak
1105078	RS Umum Graha Bunda	Aceh	Aceh Timur	Jl. Medan - Banda Aceh Bukit Pala, Idi Rayeuk - A...	Rumah Sakit Umum
1110075	RS Umum Daerah Dr. Fauziah Bireun	Aceh	Bireuen	Jl. Mayjen T. Hamzah Bendahara No. 13 Bireuen	Rumah Sakit Umum
1171143	RS Bhayangkara Banda Aceh	Aceh	Kota Banda Aceh	Jl. Cut Nyak Dhien No. 23, Lamteumen Barat Banda A...	Rumah Sakit Umum
Console					
	RS Umum Daerah Dr. H. Yulidin	Aceh	Aceh Selatan	Jl. T. Ben Mahmud Nomor 86 A Tanaktran	Rumah Sakit Umum

kelas	status_blu	kepemilikan	total_tempat_tidur	total_layanan	total_tenaga_kerja
C	Non BLU/BLUD	SWASTA/LAINNYA	218	36	328
D	Non BLU/BLUD	SWASTA/LAINNYA	45	15	45
B	BLUD	Pemkot	310	77	487
B	BLU	Kementerian Lain	11	24	0
C	BLUD	Pemkot	189	34	537
B	BLUD	Pemkab	376	80	470
D	Non BLU/BLUD	Perusahaan	102	64	208
D	Non BLU/BLUD	SWASTA/LAINNYA	88	38	128
C	BLUD	Pemkab	176	35	199
D	Non BLU/BLUD	SWASTA/LAINNYA	60	56	0
C	Non BLU/BLUD	SWASTA/LAINNYA	80	28	3
C	Non BLU/BLUD	Organisasi Sosial	163	26	315
B	BLUD	Pemkab	251	84	1178
C	BLU	POLRI	182	23	147
B	BLUD	Pemkab	359	68	515


* Star Schema

- owner dim → menyimpan informasi tentang kepemilikan
- location dim → menyimpan informasi tentang lokasi(provinsi,kab/kota,dan alamat
- jenis dim → menyimpan informasi tentang jenis dan kelas di rumah sakit








Data Processing



1. Location Dim



SDC 1



location_code	propinsi	kab	alamat
66	ACEH	ACEH BARAT	BERINGIN JAYA , KEL. SEUNUBOK KEC. JOHAN PAHLAWA...
47	ACEH	ACEH BARAT	GAJAH MADA MEULABOH
49	ACEH	ACEH BARAT	POCUT BAREN UJUNG KARANG DESA SUAK INDRAPURI KEC. ...



Table input → mengambil data alamat, kabupaten, dan provinsi

Unique Rows → menghapus duplikasi


Replace in String → memperbaiki ketidakkonsisten pada column kabupaten dan alamat

String operation → menghilangkan spasi dan upper case tiap column


insert/update → mengupdate data lama menjadi data baru



Data Processing



2. Jenis Dim



SDC 1

Table input

Step name: Table input

Connection: hasil_connection

SQL

```
SELECT
jenis
, kelas
FROM hasil.hospital
```

jenis_code	jenis	kelas
30	rumah sakit ketergantungan obat	B
25	rumah sakit khusus bedah	A
20	rumah sakit khusus bedah	B



Table input → mengambil data jenis, dan kelas


String operation → menghilangkan spasi dan upper/lower case di column tertentu

Filter rows → Penyaringan data tertentu dengan kondisi tertentu

insert/update → mengupdate data lama menjadi data baru



Data Processing



3. Owner Dim





Table input

Step name

Connection: hasil_connection

SQL

```
SELECT
  status_blu
, kepemilikan
FROM hasil.hospital
```



SDC 1

owner_code	status_blu	kepemilikan
3	BLU	Kementerian Lain
15	BLU	Kemkes
7	BLU	POLRI
8	BLU	TNI AD
4	BLUD	Pemkab
2	BLUD	Pemkot
11	BLUD	Pemprop
10	Non BLU/BLUD	BUMN
18	Non BLU/BLUD	Organisasi Budha
19	Non BLU/BLUD	Organisasi Hindu
17	Non BLU/BLUD	Organisasi Islam
13	Non BLU/BLUD	Organisasi Katholik
14	Non BLU/BLUD	Organisasi Protestan
6	Non BLU/BLUD	Organisasi Sosial
12	Non BLU/BLUD	Perorangan
5	Non BLU/BLUD	Perusahaan
1	Non BLU/BLUD	SWASTA/LAINNYA
9	Non BLU/BLUD	TNI AL
16	Non BLU/BLUD	TNI AU


Table input → mengambil data kepemilikan Rumah Sakit

Unique Rows → menghapus duplikasi


insert/update → mengupdate data lama menjadi data baru



Data Processing




4. Fact Table




- Table input → mengambil semua data rumah sakit
- Replace in String & string operation & Filter Rows → melakukan pembersihan yang sudah dilakukan di setiap dimension dimension sebelumnya.
- Database lookup 1,2,dan 3 → untuk mengambil data dari tabel database tertentu berdasarkan key tertentu.
- Select Values → untuk memilih, memproses kolom tertentu yang akan digunakan selanjutnya
- Table output → Menyimpan data yang sudah bersih pada datawarehouse/database

Data Processing



5.Orchestration



- Job ETL Data Warehouse digunakan untuk mengatur agar tabel dimensi diproses sukses sebelum tabel fakta (menjamin integritas data).
- Proses dimulai dari pemasukan tabel seperti location_dim, jenis_dim, dan owner_dim.
- Setelah pemuatan tabel dim selesai maka tabel fact dimasukan menggunakan surrogate key tabel masing-masing.
- Job diakhiri dengan success yang berarti proses ETL berjalan dengan lancar



Visualisasi Menggunakan Power BI

Tahap akhir dari seluruh pipeline data ini direalisasikan melalui pembuatan dashboard interaktif menggunakan Power BI. Sebagai Business Intelligence engine, Power BI berfungsi mentransformasikan model data Star Schema yang telah disimpan di MySQL menjadi informasi visual yang siap pakai.

Mengapa memilih Card Visual?

- Menunjukkan data penting: Menonjolkan metrik kunci agar data yang paling penting dapat langsung dilihat oleh audiens.

Mengapa memilih Map?

- Bagus untuk Persebaran: Map berfungsi untuk menunjukkan persebaran data di sebagian daerah, dalam konteks ini adalah map Indonesia.

Alasan Pemilihan Bar Chart

- Ranking: Visualisasi ini cocok untuk menampilkan urutan atau peringkat. Dengan mengurutkan data secara descending, audiens dapat langsung mengidentifikasi wilayah mana yang menempati posisi puncak.





Data Consumption

Rasio Kebutuhan Layanan Tiap Provinsi

Kategori_Kebutuhann ● Butuh ● Cukup




propinsi

- ☐ ACEH
- ☐ BALI
- ☐ BANTEN
- ☐ BENGKULU
- ☐ DKI JAKARTA
- ☐ GORONTALO
- ☐ JAMBI
- ☐ JAWA BARAT
- ☐ JAWA TENGAH
- ☐ JAWA TIMUR
- ☐ KALIMANTAN ...

Kebutuhan Staff by Provinsi

Kategori_Kebutu... ● Butuh ● Cukup



129K

Sum of total_layanan


392K

Sum of total_tempat_ti...


826K

Sum of total_tenaga_k...


Total Staff Terbanyak by Provinsi




Total Staff Terendah by Provinsi



Total Bed Terbanyak by Provinsi



Total Bed Terendah by Provinsi






Data Consumption

Analisis Visualisasi:

Dashboard tersebut menunjukkan data layanan kesehatan(RS) di seluruh provinsi Indonesia, dengan fokus utama di tiga dimensi yaitu:layanan, tempat tidur (bed), dan tenaga kerja (staff). Kategori utama dibagi menjadi dua: Butuh dan Cukup



Di Indonesia total tenaga kerja sebesar 826K, jauh lebih banyak dari total tempat tidur (392K) dan total layanan (129K). Hal ini menunjukkan rasio tenaga kerja per bed sekitar 2,1 yang tergolong wajar untuk fasilitas kesehatan. Hal tersebut hanya berlaku dilihat secara nasional tetapi tidak berlaku jika dilihat per provinsi atau per kabupaten. Masih terdapat beberapa kekurangan tenaga kerja per provinsi maupun per kabupaten.

Rasio Kebutuhan Layanan Tiap Provinsi

Kategori_Kebutuhann ● Butuh ● Cukup




- Provinsi di Pulau Jawa memiliki pie chart berukuran lebih besar → mengindikasikan volume data/populasi layanan yang jauh lebih tinggi
- Provinsi di Papua, Maluku, dan Kalimantan Timur memiliki pie chart kecil → volume layanan rendah
- Sebagian besar pie chart menunjukkan proporsi biru (Cukup) lebih dominan, namun beberapa daerah masih memiliki porsi oranye (Butuh) yang signifikan
- Menunjukkan konsentrasi tenaga kerja terbesar terkumpul di Provinsi Jawa Timur, Jawa Tengah, dan Jawa Barat, disusul oleh DKI Jakarta.



Data Consumption

Analisis Visualisasi:



- Total staff terbanyak per Provinsi:
5 dari 7 provinsi dengan total staff ter banyak berada di pulau Jawa yaitu isinya Jawa Timur, Jawa Barat, Jawa Tengah, dan Banten
- Total staff terendah per Provinsi:
Provinsi Papua mendominasi daftar kekurangan tenaga kerja. Papua Pegunungan bahkan mendekati nol (0K), ini merupakan indikator kritis kekurangan layanan kesehatan di wilayah timur Indonesia. Ini juga disebabkan karena provinsi tersebut merupakan provinsi baru juga.
- Total bed terbanyak per Provinsi:
Pola yang sama seperti dengan tenaga kerja. Jawa barat mendominasi dengan angka 61K bed
- Total bed terendah per Provinsi:
Pola yang sama juga terjadi di provinsi papua seperti halnya tenaga kerja.



Thank You

